


Raqamli tasvirlarga ishlov berish



Shovqin Modellari: Gauss va Impulsli

Gauss Shovqini — Aditiv Normal Taqsimot



Har bir pikselga mustaqil normal taqsimlangan qiymat qo'shiladi:

$$I_{\text{noisy}}(x, y) = I(x, y) + n, \quad n \sim \mathcal{N}(0, \sigma^2)$$

- Aditiv xususiyat: shovqin tasvirga mustaqil qo'shiladi
- σ kattalashganda shovqin intensivligi ortadi
- Tabiiy sensor shovqiniga yaqin model

Impulsli Shovqin — Tuz-Murch (Salt & Pepper)

- Tasodifiy piksellar 0 (qora) yoki 255 (oq) ga aylanadi
- Sensor nuqsonlari va uzatish xatolarida uchraydi
- Median filtr bilan samarali bartaraf etiladi



❏ **Ma'ruzachi izohi:** Gauss shovqini markaziy chegara teoremasi asosida ko'plab mustaqil kichik shovqin manbalarining yig'indisi sifatida paydo bo'ladi. Impulsli shovqin esa alohida piksellar darajasida "portlash" xususiyatiga ega — ular butunlay buziladi. Shuning uchun chiziqli filtrlar (Gaussian blur) impulsli shovqin uchun samarasiz: ular ekstremal qiymatlarni qo'shni piksellarga "tarqatib" yuboradi. Median filtr esa qiymatlarni saralash orqali ekstremallarni avtomatik chiqarib tashlaydi.

Fazoviy Filtrlash: Gauss, Median va Bilateral

Gaussian Blur

Chiziqli past chastotali filtr. Yadro:

$$G(x, y) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}}$$

Shovqinni tekislashtiradi, lekin chegaralarni xiralashtiradi.

Median Blur

Nochiziqli filtr — mahalliy oyna ichida medianani oladi:

$$I_{\text{out}}(x, y) = \text{median}\{I(x + i, y + j)\}$$

Impulsli shovqin uchun optimal; chegaralarni saqlaydi.

Bilateral Filter

Ikkita yadro: fazoviy w_s va rang w_r :

$$I_{\text{out}}(x) = \frac{1}{W} \sum_y w_s(\|x - y\|) w_r(|I(x) - I(y)|) I(y)$$

Chegaralarni saqlab shovqinni kamaytiradi.

- ❏ **Ma'ruzachi izohi:** Bilateral filtrning asosiy ustunligi — u ikki o'lchovli vazn funksiyasidan foydalanadi: fazoviy yaqinlik (gauss yadrosi) va rang o'xshashligi. Agar qo'shni piksel rang jihatidan juda farq qilsa (masalan, chegara bo'ylab), uning vazni kichik bo'ladi va u silliqlashga hissa qo'shmaydi. Shu sababli chegaralar saqlanadi. σ_s (spatial sigma) fazoviy qo'shnilikni, σ_r (range sigma) esa rang o'xshashligi darajasini boshqaradi. Amaliyotda σ_r ni juda katta qo'ysangiz, filtr oddiy Gaussian blur ga aylanadi.

Tasvir Sifatini Baholash: PSNR va SSIM

PSNR — Pik Signali-Shovqin Nisbati

$$\text{MSE} = \frac{1}{MN} \sum_{i=0}^{M-1} \sum_{j=0}^{N-1} [I(i, j) - K(i, j)]^2$$

$$\text{PSNR} = 10 \log_{10} \left(\frac{\text{MAX}_I^2}{\text{MSE}} \right)$$

- Odatda 30–50 dB oralig'ida o'lchanadi
- Yuqori qiymat = yaxshi sifat
- Kamchiligi: inson idrokini to'liq aks ettirmaydi

SSIM — Strukturaviy O'xshashlik Indeksi

$$\text{SSIM}(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)}$$

- **Yorug'lik:** $l(x, y) = \frac{2\mu_x\mu_y + C_1}{\mu_x^2 + \mu_y^2 + C_1}$
- **Kontrast:** $c(x, y) = \frac{2\sigma_x\sigma_y + C_2}{\sigma_x^2 + \sigma_y^2 + C_2}$
- **Struktura:** $s(x, y) = \frac{\sigma_{xy} + C_3}{\sigma_x\sigma_y + C_3}$

❏ **Ma'ruzachi izohi:** PSNR ning asosiy kamchiligi — u faqat piksel darajasidagi xatolikni o'lchaydi, lekin strukturaviy o'zgarishlarni hisobga olmaydi. Masalan, tasvirni bir piksel siljitish PSNR ni keskin tushiradi, garchi inson ko'ziga deyarli o'zgarishsiz ko'rinadi. SSIM bu muammoni hal qiladi: u uchta komponentni — yorug'lik, kontrast va struktura — alohida baholaydi va ularni ko'paytiradi. C_1 va C_2 barqarorlashtiruvchi konstantalar bo'lib, maxraj nolga teng bo'lishining oldini oladi. SSIM = 1 ideal holat, 0 dan kichik qiymatlar esa tasvirlar o'rtasida teskari korrelyatsiya borligini bildiradi.

Tasvir Aniqligi va Filtr Darchasi Ta'siri

Fazoviy Qamrov (Spatial Coverage) Muammosi



Kichik tasvir — 32×32 (CIFAR-10)

5×5 filtr darchasi tasvirning ~15% ini qoplaydi. Har bir konvolyutsiya amali global xiralashishga olib keladi, nozik teksturalar yo'qoladi.

Yuqori aniqlik — 1024×1024

5×5 darcha atigi 0.002% ni tashkil etadi. Mo'yna, barg kabi lokal teksturalar saqlanib qoladi, global blur minimal.

i Filtr o'lchamini tasvir masshtabiga nisbatan tanlash — kritik dizayn qarori.

Ma'ruzachi izohi: Bu muammo ayniqsa chuqur o'rganish arxitekturalarida muhim. CIFAR-10 kabi kichik tasvirlarda katta filtr darchalari (masalan, 7×7) deyarli butun tasvirni qamrab oladi va ma'lumotni yo'qotadi. Shu sababli zamonaviy arxitekturalarda (ResNet, EfficientNet) kichik tasvirlarda 3×3 filtrlar afzal ko'riladi. Yuqori aniqlikdagi tasvirlarda esa 5×5 yoki 7×7 filtrlar mahalliy xususiyatlarni saqlagan holda samarali ishlaydi. Amaliyotda filtr o'lchamini tanlashda tasvir o'lchami, teksturaning nozikligi va maqsadli vazifa (klassifikatsiya, segmentatsiya, deteksiya) birga hisobga olinishi kerak.

Matritsali Konvolyutsiya va Optimallashtirish

Zero-Copy Optimallashtirish — NumPy

```
from numpy.lib.stride_tricks import sliding_window_view

# Zero-copy sliding windows
windows = sliding_window_view(img, (kH, kW)) # (H-kH+1, W-kW+1, kH, kW)


# Vectorized dot-product (no Python loops)
out = np.einsum('ijkl,kl->ij', windows, kernel)
```

OpenCV vs Matematik Konvolyutsiya


`cv2.filter2D` kross-korrelyatsiya bajaradi. Haqiqiy konvolyutsiya uchun yadroni aylantirish shart:

```
out_math = cv2.filter2D(img, -1, kernel[::-1, ::-1])
```

Ikki bosqichli taqqoslash:
Chapda - Naive Loop usuli
(Python for tsikllari,
har bir piksel alohida,
sekin, $O(H*W*kH*kW)$)




O'ngda - Vectorized usuli
(`sliding_window_view` zero-copy,
`np.einsum` barcha hisoblashni
bir marta bajaradi,
50-100x tez)



- ❏ **Ma'ruzachi izohi:** `sliding_window_view` ning afzalligi shundaki, u tasvir ma'lumotlarini nusxalamasdan faqat stride (qadam) parametrlarini o'zgartiradi — bu zero-copy operatsiya. `np.einsum` esa barcha oyna-kernel ko'paytmalarini bir vaqtning o'zida, BLAS kutubxonasi yordamida bajaradi. Natijada, naive Python tsikli bilan solishtirganda 50-100 baravar tezlashish kuzatiladi. OpenCV ning `filter2D` funksiyasi matematik konvolyutsiya emas, balki kross-korrelyatsiya bajaradi — farq shundaki, konvolyutsiyada yadro 180 gradusga aylantiriladi. Agar yadro simmetrik bo'lmasa (masalan, Sobel), bu farq natijaga ta'sir qiladi.

Gauss Silliqlashi va Sobel Gradientlari



**Gauss
Silliqlash**

**Sobel
Gradienti**

Separable Gauss yadrosi $g \otimes g^T$ samarali silliqlaydi. Sobel operatorlari gradient vektorini hisoblaydi:

$$|G| = \sqrt{G_x^2 + G_y^2}, \quad \theta = \arctan\left(\frac{G_y}{G_x}\right)$$

```
Gx = cv2.Sobel(img, cv2.CV_64F, 1, 0, ksize=3)
Gy = cv2.Sobel(img, cv2.CV_64F, 0, 1, ksize=3)
magnitude = np.hypot(Gx, Gy)
direction = np.arctan2(Gy, Gx) # [-π, π]
```


- ❏ **Ma'ruzachi izohi:** Separable Gauss filtri ikki ketma-ket 1D konvolyutsiyadan iborat: avval gorizontal yo'nalishda, keyin vertikal yo'nalishda. Bu 2D yadrodan foydalanishga qaraganda hisoblash jihatidan ancha samarali: $O(k^2)$ o'rniga $O(2k)$. Sobel operatorlari 3×3 yadro yordamida gorizontal (G_x) va vertikal (G_y) gradientlarni hisoblaydi. `np.hypot` funksiyasi sonli barqarorlik uchun afzal — u $G_x^2 + G_y^2$ ni to'g'ridan-to'g'ri hisoblash o'rniga, ortiqcha katta sonlar paydo bo'lishining oldini oladi. θ burchagi $[-\pi, \pi]$ oralig'ida bo'lib, keyingi NMS bosqichida 4 diskret yo'nalishga kvantlanadi.

No-Maksimumlarni Bostirish (NMS) va Kvantlash

NMS Algoritmi

Gradient yo'nalishi bo'ylab faqat lokal maksimum piksellar saqlanadi:

- θ ni 4 diskret burchakka kvantlash: 0° , 45° , 90° , 135°
- Har bir yo'nalish bo'yicha ikki qo'shnini solishtirish
- Maksimum bo'lmagan piksellar 0 ga tenglanadi



```
angle_q = (np.rad2deg(direction) + 180) % 180
angle_q = np.round(angle_q / 45) * 45 # 4 diskret burchak

# 0° gorizontal qo'shnilar
mask = (angle_q == 0)
suppress = (magnitude < np.roll(magnitude, 1, axis=1)) | \
            (magnitude < np.roll(magnitude, -1, axis=1))
magnitude[mask & suppress] = 0
```

❏ **Ma'ruzachi izohi:** NMS ning mohiyati — gradient yo'nalishi bo'ylab faqat eng kuchli piksellar saqlanadi, qolganlari bostiriladi. Masalan, agar gradient 0° (gorizontal) bo'lsa, piksel chap va o'ng qo'shnilari bilan solishtiriladi. Agar u ikkalasidan ham katta bo'lsa — chegara pikseli sifatida saqlanadi, aks holda 0 ga tenglanadi. Kvantlash 4 ta burchakka amalga oshiriladi, chunki haqiqiy burchakni aniq hisoblash o'rniga diskretlashtirish hisoblash samaradorligini oshiradi va interpolyatsiya orqali yanada aniq natija olish mumkin. `np.roll` funksiyasi massivni siljitish orqali qo'shni piksellarga murojaat qilish imkonini beradi — bu tsiklsiz vektorlashtirilgan yondashuv.

Gisterezis Ostonalash va BFS Qidiruv

Ikki Ostonali Strategiya

Kuchli chegara

$Magnitude > T_{high}$ —
darhol qabul qilinadi

Kuchsiz chegara

$T_{low} < Magnitude \leq T_{high}$
— qo'shni kuchli piksel
bo'lsa saqlanadi

Rad etilgan

$Magnitude \leq T_{low}$ — to'liq o'chiriladi

BFS Orqali Kuchsiz Chegaralarni Tiklash


```
from collections import deque

def connect_weak_edges(strong, weak):
    h, w = strong.shape
    visited = np.zeros_like(strong, dtype=bool)
    queue = deque(np.argwhere(strong == 2)) # kuchli
    pikseller

    while queue:
        y, x = queue.popleft()
        for dy, dx in [(-1,0),(1,0),(0,-1),(0,1),
                       (-1,-1),(-1,1),(1,-1),(1,1)]:
            ny, nx = y+dy, x+dx
            if 0 <= ny < h and 0 <= nx < w:
                if weak[ny, nx] == 1 and not visited[ny, nx]:
                    strong[ny, nx] = 2 # kuchli ga aylantir
                    visited[ny, nx] = True
                    queue.append((ny, nx))
    return strong
```

- 📌 **Ma'ruzachi izohi:** Gisterezis ostonalash Canny algoritmining eng aqlli bosqichi hisoblanadi. Bitta ostonadan foydalansangiz, yo kuchli chegaralar uzilib qoladi (ostona yuqori bo'lsa), yo shovqin chegaralar sifatida aniqlanadi (ostona pastki bo'lsa). Ikki ostonali yondashuv bu muammoni hal qiladi: kuchli pikseller ishonchli chegara deb qabul qilinadi, kuchsiz pikseller esa faqat kuchli pikselga tutashgan bo'lsa saqlanadi. BFS (Breadth-First Search) algoritmi kuchli pikseldan boshlab 8 yo'nalishda qo'shnilarni tekshiradi va kuchsiz piksellarni "kuchli" ga aylantiradi. Bu uzilgan chegara chiziqlarini tiklash imkonini beradi. Odatda $T_{high} = 2 \times T_{low}$ nisbati ishlatiladi.

Amaliy Natijalar, Metrikalar Taqqoslovi va Xulosalar



Asosiy Xulosalar

→ Shovqin modeli → Filtr tanlovi

Gauss shovqini → Gaussian/Bilateral; Impulsi → Median filtr optimal.

→ SSIM > PSNR

SSIM inson idrokini aniqroq aks ettiradi; PSNR faqat piksel darajasida xatolikni o'lchaydi.

→ Canny — optimal chegara detektor

NMS + Gisterezis kombinatsiyasi IoU bo'yicha boshqa usullardan ustun.

→ Masshtab muammosi

Filtr darchasi tasvir o'lchamiga nisbatan tanlanishi shart — global blur oldini olish uchun.

❏ **Ma'ruzachi izohi:** IoU (Intersection over Union) metrikasi — bu haqiqiy chegara maskasi bilan aniqlangan chegara maskasi o'rtasidagi kesishma nisbati. Canny detektor barcha usullar orasida eng yuqori IoU ko'rsatkichiga ega, chunki u uch bosqichli strategiyadan foydalanadi: silliqlash (shovqinni kamaytirish), NMS (noaniq chegaralarni yo'qotish) va gisterezis (uzilgan chiziqlarni tiklash). OpenCV implementatsiyasi custom NumPy versiyasidan biroz yaxshiroq natija beradi, chunki u optimallashtirilgan C++ kodi va sub-piksel aniqlikdagi interpolyatsiyadan foydalanadi. Keyingi mavzular sifatida morfologik operatsiyalar, Hough transformatsiyasi va zamonaviy deep learning asosidagi chegara detektorlarini (HED, PiDiNet) o'rganish tavsiya etiladi.